Text Analysis with NLP Case study: Phân tích quan điểm

TS. Nguyen Van Vinh QAI, Fsoft

Giới thiệu về giảng viên

- TS. Nguyễn Văn Vinh
- PhD tại Viện Khoa học Công nghệ tiên tiến Nhật Bản (JAIST)
- Lĩnh vực nghiên cứu: Trí Tuệ Nhân Tạo, Xử lý ngôn ngữ tự nhiên, Dữ liệu lớn
- Giảng viên Khoa CNTT, Chuyên gia AI Trường ĐHCN ĐHQG Hà Nội
- Senior Data Scientist, Công ty QAI, Fsoft
- Trưởng nhóm thiết kế khóa học <u>Machine Learning</u> của FUNiX (https://vnexpress.net/giao-duc/funix-ra-mat-chuong-trinh-machine-learning-3986011.html)
- Đã từng trình bày và giảng bài: Samsung Việt Nam, VNG, Ban cơ yếu chỉnh phủ, Viện Vin BigData ...

Adrew Ng

• "NLP is reshaping daily life. No doubt you've found valuable information using web search and the search functions found on countless websites and apps. Anti-spam systems are a critical part of the global email system. How does a smart speaker understand your commands? How does a chatbot generate relevant responses? "

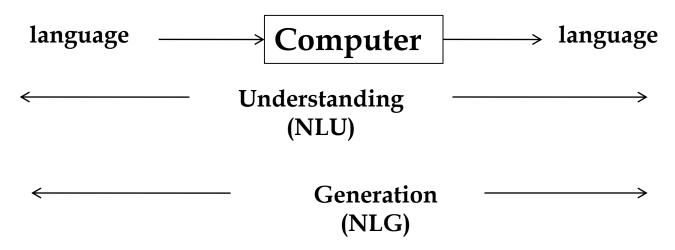
Nội dung

- Bài toán xử lý ngôn ngữ tự nhiên
- Úng dụng: Bài toán Phân tích quan điểm

BÀI TOÁN XỬ LÝ NGÔN NGỮ TỰ NHIÊN (NLP)

Xử lý ngôn ngữ tự nhiên là gì?

 Computers using natural language as input and/or output



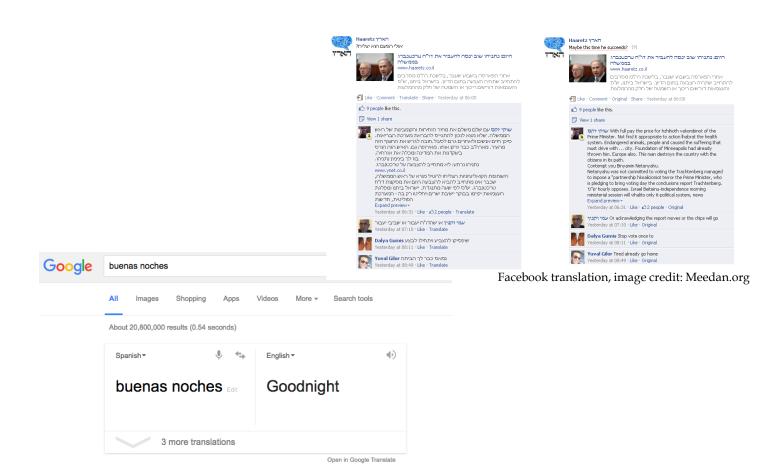
Go beyond the keyword matching





- Identify the structure and meaning of words, sentences, texts and conversations
- Deep understanding of broad language
- NLP is all around us

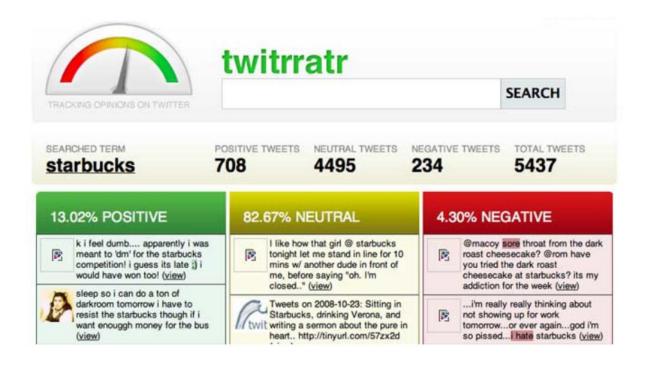
Machine translation



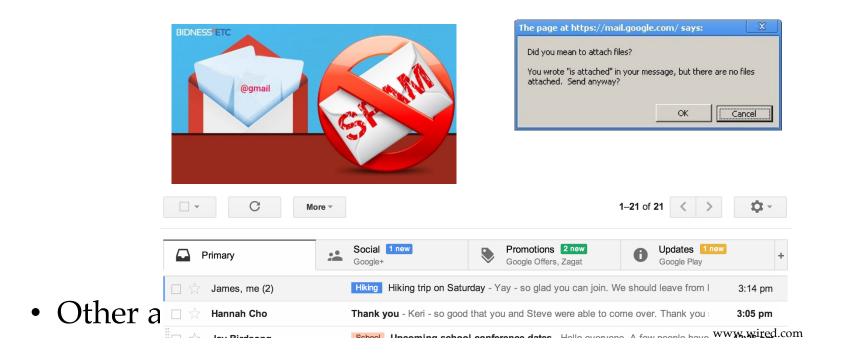
Dialog Systems/Chatbot



Sentiment/Opinion Analysis



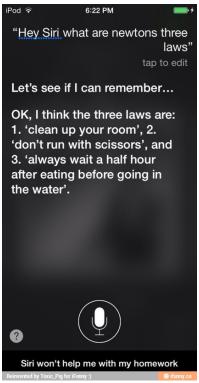
Text Classification



Question answering



'Watson' computer wins at 'Jeopardy'



credit: ifunny.com

Question answering

• Go beyond search



Natural language instruction



https://youtu.be/KkOCeAtKHIc?t=1m28 <u>s</u>

Digital personal assistant

More on natural language instruction





- Semantic parsing understand tasks
- Entity linking "my wife" = "Kellie" in the phone book

Information Extraction

Unstructured text to database entries

New York Times Co. named Russell T. Lewis, 45, president and general manager of its flagship New York Times newspaper, responsible for all business-side activities. He was executive vice president and deputy general manager. He succeeds Lance R. Primis, who in September was named president and chief operating officer of the parent.

Person	Company	Post	State
Russell T. Lewis	New York Times newspaper	president and general manager	start
Russell T. Lewis	New York Times newspaper	executive vice president	end
Lance R. Primis	New York Times Co.	president and CEO	start

Yoav Artzi: Natural language processing

BÀI TOÁN PHÂN TÍCH QUAN ĐIỂM

Positive or negative movie review?

- unbelievably disappointing
- Full of zany characters and richly applied satire, and some great plot twists
- this is the greatest screwball comedy ever filmed
- It was pathetic. The worst part about it was the boxing scenes.

Google Product Search



HP Officejet 6500A Plus e-All-in-One Color Ink-jet - Fax / copier / printer / scanner \$89 online, \$100 nearby ★★★★ 377 reviews

September 2010 - Printer - HP - Inkjet - Office - Copier - Color - Scanner - Fax - 250 sho

Reviews

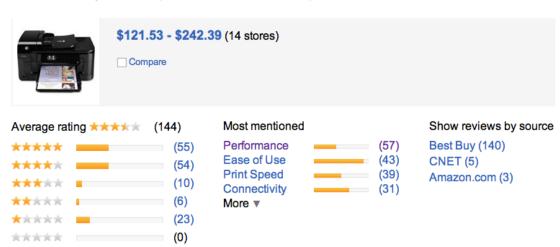
Summary - Based on 377 reviews

1 star	2	3	4 stars	5 stars
What people a ease of use value setup customer serv size mode colors			ng	"This was very easy to setup to four computers." "Appreciate good quality at a fair price." "Overall pretty easy setup." "I DO like honest tech support people." "Pretty Paper weight." "Photos were fair on the high quality mode." "Full color prints came out with great quality."

Bing Shopping

HP Officejet 6500A E710N Multifunction Printer

Product summary Find best price Customer reviews Specifications Related items



Bài toán phân tích quan điểm

- Input: Cho một câu (đoạn) văn bản.
- Ouput: Xác định câu này là câu tích cực (1) hoặc tiêu cực (0).
- Thực hiện trên bộ dữ liệu review phim ảnh: IMDB

Phân tích quan điểm

- Chuẩn bị dữ liệu: IMDB Movie Reviews
- Tiền xử lý dữ liệu
- Trích trọn đặc trưng (Vectorization)
- Chọn mô hình học máy và huấn luyên

Tiền xử lý dữ liệu

• Đơn vị nhỏ nhất là từ. Dãy các từ:

Ví dụ:

Text: This is a cat. --> **Word Sequence:** [this, is, a, cat]

- Dữ liệu crawl từ web thường rất là "dirty" như mã Html, các từ viết tắt, ... nên cẩn phải tiền xử lý dữ liệu
- Dùng biểu thức chính qui thực hiện

Biểu thức chính qui

- Biêu thức chính qui (or **regex**) is a sequence of characters that represent a search pattern
- Each character has a meaning; for example, ". means any character that isn't the newline character: '\n'"
- These characters are often combined with quantifiers, such as *, which means zero or more.
- Biểu thức chính qui rất có ích trong việc xử lý xâu ký tự

Biểu thức chính qui

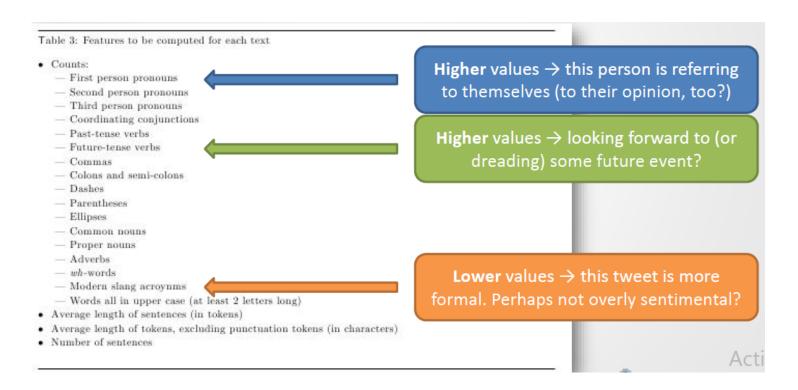
SYMBOL	USAGE
\$	Matches the end of the line
\s	Matches whitespace
\\$	Matches any non-whitespace character
*	Repeats a character zero or more times
\\$	Matches any non-whitespace character
*?	Repeats a character zero or more times (non-greedy)
+	Repeats a character one or more times
+?	Repeats a character one or more times (non-greedy)
[aeiou]	Matches a single character in the listed set
[^XYZ]	Matches a single character not in the listed set
[a-z0-9]	The set of characters can include a range

Bài tập nhanh

- Ví dụ:
- 1) Trính ra số từ s:
- s = 'My 2 favourite numbers are 8 and 25. My mobie is 0912203062'.
- 1) Trích ra email từ s:
- s = 'Hello from shubhamg199630@gmail.com to priya@yahoo.com and bigdata@Samsung.com about the meeting @2PM'

Vector đặc trưng

Các đặc trưng sẽ hữu ích trong việc phân biệt giữa các thể loại



Trích trọn đặc trưng

- Chúng ta gọi vectơ hóa (vectorization) là quá trình chung biến tập các tài liệu văn bản thành các vectơ đặc trưng số thực
- Kỹ thuật vector hóa đơn giản nhất là Bag Of Words (BOW).
 It starts with a list of words called the vocabulary (this is often all the words that occur in the training data)

Trích trọn đặc trưng

- To use BOW vectorization in Python, we can rely on CountVectorizer from the scikit-learn library
- scikit-learn has a built-in list of stop words that can be ignored by passing stop_words="english" to the vectorizer
- Moreover, we can pass our custom pre-processing function fromearlier to automatically clean the text before it's vectorized.

Training texts: ["This is a good cat", "This is a bad day"]=>

vocabulary: [this, cat, day, is, good, a, bad]

New text: "This day is a good day" --> [1, 0, 2, 1, 1, 1, 0]

Ứng dụng cho bài toán phân tích quan điểm

- Dữ liệu văn bản IMDB: The IMDB movie reviews dataset is a set of 50,000 reviews, half of which are positive and the other half negative
- Chúng ta có thể download dữ liệu từ:

http://ai.stanford.edu/~amaas/data/sentiment/aclImdb_v1.tar.gz

- Chúng ta có thư mục chứa dữ liệu là: aclImdb
- we can use the following function to load the training/test datasets from IMDB

Ứng dụng cho bài toán phân tích quan điểm

- feature vectors that result from BOW are usually very large (80,000-dimensional vectors in this case)
- we need to use simple algorithms that are efficient on a large number of features (e.g., Naive Bayes, linear SVM, or logistic regression)

Cải tiến mô hình hiện tại

- Trích trọng đặc trưng rất là quan trọng (Features Engineering
- There are some biases attached with only looking at how many times a word occurs in a text. In particular, the longer the text, the higher its features (word counts) will be
- Dựa vào đặc trưng TF-IDF
- Dựa vào n-gram

Cải tiến mô hình

- Đặc trưng TF-IDF
- Chúng ta có thể huấn luyện mô hình Linear SVM với đặc trưng TF-IDF đơn giản bằng việc thay thế hàm CountVectorizer bằng hàm TfIdfVectorizer
- Kết quả tăng khoảng 2%

$$TF(word, text) = \frac{\text{number of times the word occurs in the text}}{\text{number of words in the text}}$$

$$IDF(word) = \log \left[\frac{\text{number of texts}}{\text{number of texts where the word occurs}} \right]$$

$$TF-IDF(word, text) = TF(word, text) \times IDF(word)$$

Cải tiến mô hình

- Sử dụng các từ độc lập sẽ không tốt. Ví dụ:
- if the word good occurs in a text, we will naturally tend to say that this text is positive, even if the actual expression that occurs is actually not good. Cum từ tốt hơn
- Sử dụng n-gram để xử lý vấn đề này
- An N-gram is a set of N successive words (e.g., very good [2-gram] and not good at all [4-gram]). Using N-grams, we produce richer word sequences.
- Ví dụ với N =2:

This is a cat. --> [this, is, a, cat, (this, is), (is, a), (a, cat)]

Cải tiến mô hình

• In practice, including N-grams in our TF-IDF vectorizer is as simple as providing an additional parameter ngram range=(1, N).

Summary

- 1. Giới thiệu về bài toán NLP
- 2. Mô hình Logistic regression là phân lớp tuyến tính đơn giản nhưng hiệu quả
- 3. Thực hành với bài toán phân tích quan điểm